



Trabajo Almacenes de Datos

Integración de datos (ETL) de un almacén de UCI Sanitaria

Realizado por De Pablo Diego y Soriano Juan

Profesor encargado: Luque Baena Rafael Marcos

Departamento
Lenguajes y Ciencias de la Computación

MÁLAGA, DICIEMBRE de 2024





ESCUELA TÉCNICA SUPERIOR DE INGENIERÍA INFORMÁTICA ESTUDIANTES DE INGENIERÍA BIOINFORMÁTICA

Integración de datos (ETL) de un almacén de UCI Sanitaria

Almacenes de Datos

Realizado por **De Pablo Diego y Soriano Juan**

Profesor encargado: Luque Baena Rafael Marcos

Departamento
Lenguajes y Ciencias de la Computación

UNIVERSIDAD DE MÁLAGA MÁLAGA, DICIEMBRE DE 2024

Contents

1	Introducción		3
2	Objetivos		3
3	Modificación del almacén de datos		3
	3.1 Ingreso a la UCI		4
	3.2 Tiempo de Alta		5
	3.3 Paciente		5
	3.4 Supreción de Respiratory Charting		5
	3.5 Relaciones entre Tablas		5
4	ETL del almacén de datos NorthwindDW		6
	4.1 Dificultades en Northwind		7
5	ETL del almacén de datos de pacientes con patologías respirator	rias	9
	5.1 Carga de Región		11
	5.2 Carga de Género y Etnia		11
	5.3 Carga Tiempo		12
	5.4 Carga Priority		13
	5.5 Carga Tipo		13
	5.6 Carga RouteAdmin		13
	5.7 Carga Hospital		13
	5.8 Carga Paciente		14
	5.9 Carga IngresoUCI		17
	5.10 Carga Diagnosis		19
6	Dificultades encontradas		19
7	Conclusiones		22
8	Github y conjunto de instrucciones para su correcto despliegue	e en	
	SQL Server.		22

1 Introducción

Este documento constituye una continuación del trabajo previo, donde se desarrolló el diseño conceptual y lógico de un almacén de datos basado en la información proporcionada por la Base de Datos de Investigación Colaborativa eICU [1]. En ese proyecto, el enfoque principal fue la selección y análisis de información relativa a pacientes con patologías respiratorias, determinando las tablas y columnas más relevantes para permitir un análisis exhaustivo de esta población específica.

En esta nueva fase, se procederá a la implementación del proceso de **Extracción**, **Transformación y Carga** (ETL, por sus siglas en inglés). Este proceso es fundamental para la integración de datos en cualquier almacén de datos, ya que permite extraer datos de múltiples fuentes, transformarlos según las necesidades del modelo, y finalmente cargarlos en el sistema de almacenamiento. El proceso ETL es clave para garantizar la calidad, consistencia e integridad de los datos, factores esenciales para que el análisis posterior sea preciso y confiable.

El éxito de este proceso asegura que las tablas del almacén de datos estén adecuadamente pobladas con información precisa, sentando las bases para un **análisis de datos** eficiente. Este proceso facilita la realización de consultas complejas o la integración de herramientas como *Reporting Services*, que permiten la visualización clara y sencilla de la información más relevante, apoyando la toma de decisiones clínicas fundamentadas.

Por lo tanto, este documento también incluirá un tutorial detallado del proceso de carga para las tablas del almacén de datos personalizado. Además, se presentará un análisis de las dificultades encontradas durante la implementación y las estrategias empleadas para superarlas.

2 Objetivos

El principal objetivo de este informe es documentar de manera detallada la ejecución del proceso ETL en dos contextos diferentes:

- El almacén de datos *NorthwindDW*, utilizado como referencia durante las sesiones prácticas, cuya carga será replicada siguiendo los procedimientos previamente establecidos.
- El almacén de datos del *eICU*, adaptado específicamente para el análisis de **pacientes con patologías respiratorias**, que será implementado utilizando el modelo lógico desarrollado en la fase anterior del proyecto.

A lo largo del documento se mostrará cómo se ha llevado a cabo la integración de datos en ambos almacenes, resaltando los desafíos enfrentados y las soluciones aplicadas, con el fin de proporcionar una guía clara y replicable del proceso.

3 Modificación del almacén de datos

Durante la implementación del almacén de datos se realizaron diversas modificaciones en su estructura original, con el fin de adaptarlo lo mejor posible siguiendo

las mejores prácticas para crear un buen almacén de datos. A continuación, se detallan los principales cambios efectuados y la justificación detrás de cada uno de ellos (puede ver también la figura 1).

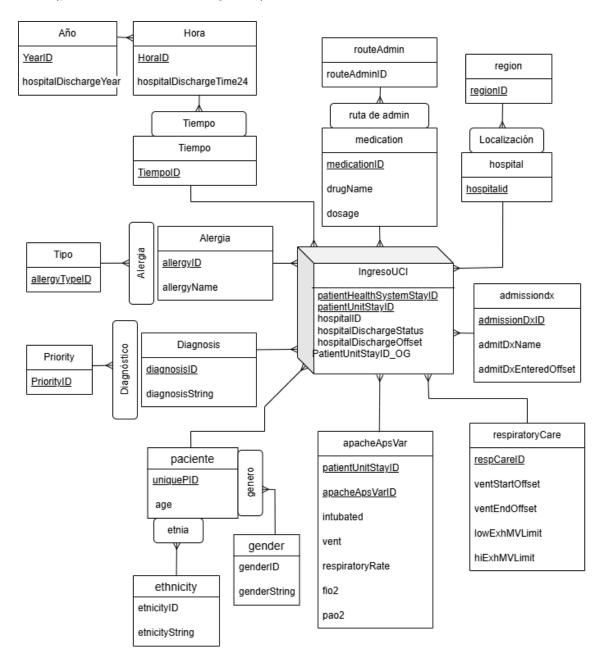


Figure 1: Diagrama actualizado (Correcciones implementadas)

3.1 Ingreso a la UCI

El mayor cambio que hubo es que el hecho Ingreso a la UCI fue separado de la tabla paciente, Además se incorporó el atributo hospitalDischargeOffset, que indica la duración de la estancia del paciente en la UCI, medida en minutos desde el ingreso hasta el alta hospitalaria. Este ajuste fue sugerido para permitir el análisis del tiempo de hospitalización de cada paciente, un factor relevante en los estudios

de recuperación y tratamiento de enfermedades respiratorias.

3.2 Tiempo de Alta

Para estudiar el tiempo en este proyecto se decidió almacenar únicamente los atributos hospitalDischargeTime24 y hospitalDischargeYear, ya que la base de datos no contiene un campo hospitalAdmitYear, como se había sugerido originalmente. Esta decisión se tomó con base en la disponibilidad de datos y la coherencia con el diseño del modelo lógico.

3.3 Paciente

La tabla **Paciente**, cuyo identificador único (PK) es el campo uniquePID. Además de este identificador, se incluyeron atributos relevantes como la edad. También se estableció una jerarquía paralela para género y etnia, lo que permitió organizar estos atributos de forma más estructurada y lógica.

3.4 Supreción de Respiratory Charting

La tabla **Respiratory Charting**, fue eliminada al trabajar más detenidamente en ella se observó múltiples inconsistencias como es la baja cantidad de datos en comparación a otros datos, cierto parentesco para algunas métricas que ya se calculaban en *ApacheApsVar* y que dependiendo del paciente se le hacía una métrica especifica, lo cual terminaba siendo rellenado con cierta cantidad de errores. En búsqueda de mantener un almacén más claro y simple se elimina esta tabla del DDL.

3.5 Relaciones entre Tablas

A continuación se describen las relaciones establecidas entre las tablas del almacén de datos, modificadas para garantizar un diseño coherente y funcional:

1. Paciente

Relación: 1-n

Cada paciente puede tener múltiples ingresos a la UCI, lo que refleja que un mismo paciente puede ser readmitido en distintos momentos debido a recaídas o nuevas patologías.

2. Diagnosis

Relación: n-m

Un paciente puede tener múltiples diagnósticos asociados a un único ingreso, y el mismo diagnóstico puede repetirse en diferentes ingresos y entre distintos pacientes.

3. Medicamentos

Relación: n-m

Un ingreso puede estar asociado a la administración de varios medicamentos. Además, un medicamento puede ser utilizado en distintos ingresos de múltiples pacientes.

4. Alergia

Relación: n-m

Cada paciente puede tener múltiples alergias documentadas, las cuales son relevantes para su tratamiento durante cada ingreso a la UCI. Por lo tanto, una alergia puede estar relacionada con múltiples ingresos.

5. RespiratoryCare

Relación: 1-n

Similar a *RespiratoryCharting*, cada ingreso puede tener múltiples intervenciones de cuidado respiratorio, como la administración de oxígeno o ventilación mecánica, asociadas a un ingreso específico.

6. apacheApsVar

Relación: 1-1

Cada ingreso a la UCI tiene una única evaluación APS asociada. Dependiendo del diseño, esta relación puede ser de uno a uno (si se almacena como un único resumen por ingreso) o de uno a muchos (si se almacena como varios componentes individuales evaluados), se decidió que la primera forma otorga más información y mayor relación con el hecho.

7. Admissiondx

Relación: 1-n

Cada ingreso tiene un diagnóstico primario de admisión, aunque pueden existir diagnósticos más concretos que se documentan en otra tabla, como *Diagnosis* que contiene información más clara y estudiada.

8. Hospital

Relación: 1-n

Cada hospital puede tener múltiples ingresos a la UCI. Los ingresos se asocian exclusivamente a un hospital, dependiendo del centro de atención en el que se encuentre la unidad.

Los cambios en las relaciones entre tablas buscan optimizar el diseño del almacén de datos, adaptándolo a las necesidades específicas del análisis clínico de los pacientes con patologías respiratorias. Estas modificaciones garantizan la integridad de los datos y la flexibilidad para realizar análisis detallados en contextos hospitalarios.

4 ETL del almacén de datos NorthwindDW

Sección de muestre la imagen de la carga completa de NorthwindDW, con todos los "ticks" en verde.

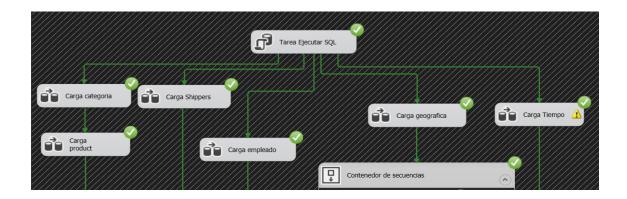


Figure 2: Flujo ETL Nortwind PT1

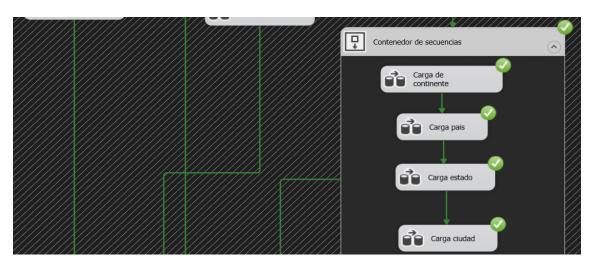


Figure 3: Flujo ETL Nortwind PT2

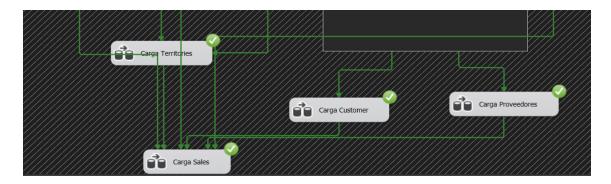


Figure 4: Flujo ETL Nortwind PT3

4.1 Dificultades en Northwind

Debido a que el archivo original, Time.xls, estaba en un formato antiguo, fue necesario transformarlo a Time.xlsx. Aunque se intentó especificar el origen como "Excel 1997", no fue posible reconocer la columna correctamente. Tras realizar la conversión al formato Excel 2007-2010, el sistema logró identificar sin problemas la columna Feuil.

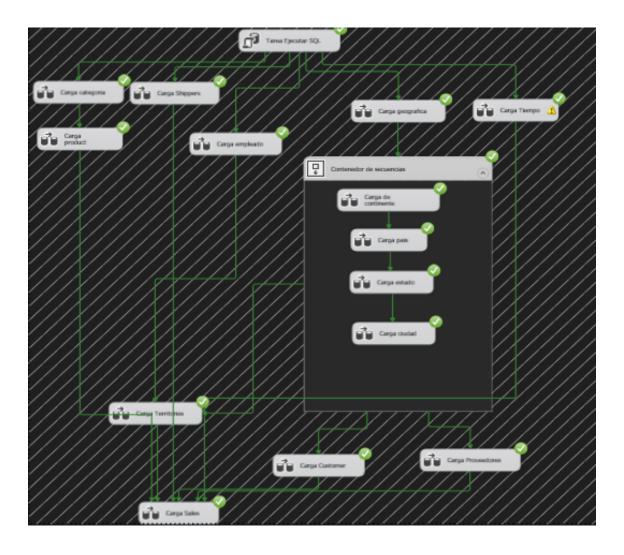


Figure 5: Flujo ETL Nortwind completo

Otra dificultad que enfrentamos fue durante el vaciado del almacén de datos, específicamente con las claves foráneas (FK). El problema surgía porque, en algunos casos, se eliminaban primero los registros asociados a la clave primaria (PK), lo que generaba conflictos con las claves foráneas dependientes. Para resolver este inconveniente, decidimos deshabilitar temporalmente las restricciones de las claves foráneas antes de realizar el vaciado del almacén y, una vez completado, las volvimos a habilitar.

- Desactivar las restricciones de clave foránea temporalmente EXEC sp_MSForEachTable 'ALTER TABLE ? NOCHECK CONSTRAINT ALL';
- Reactivar las restricciones de clave foránea EXEC sp_MSForEachTable 'ALTER TABLE ? WITH CHECK CHECK CONSTRAINT ALL';

5 ETL del almacén de datos de pacientes con patologías respiratorias

Aquí creo que sería bueno aclarar lo de las claves del hecho y sobre porque se guardo el atributo PatientOG

Así mismo en este apartado se explicará más detenidamente todo el proceso de carga aplicado para este proyecto, partiendo desde el uso de *Microsoft SQL Server Management Studio* para restaurar las bases de datos, tanto la fuente de datos correspondiente a La base de datos de investigación colaborativa, *eICU Collaborative Research Database*, disponible en este enlace. Además del *DDL* creado específicamente para esta actividad, accesible en el repositorio de GitHub a través de este enlace. A partir de un enfoque para pacientes con patología respiratorias

Una vez restaurada las bases de datos y preparadas sus conexiones para el repositorio de *Visual Studio*, *SQL Server Integration Services Project*, se podrá empezar el proceso de ETL a nuestro nuevo Data Warehouse (DW), como se observa en la figura 6 al contar con gran cantidad de tablas en el modelo copo de nieve resultará bastantes flujos de datos en nuestro repositorio.

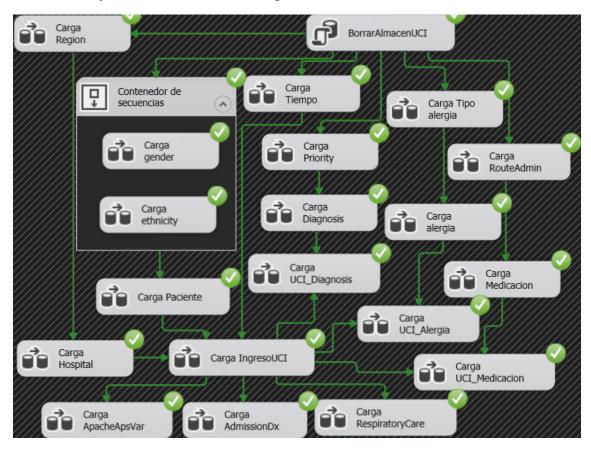


Figure 6: Flujo de control una vez acabado el ETL

A continuación la explicación tarea por tarea de cada actividad planteada en el flujo de control, es importante destacar que el trabajo sigue cierta secuencialidad en algunas secciones que dependen de fases anteriores, se íntentará destacar la paralelización de tareas y la tarea previa a cada actividad pero es importante seguir las flechas mostradas en la figura 6.

La primera actividad por excelencia en cualquier proyecto de integración de servicios es BorrarAlmacenUCI, para evitar duplicar datos al crear la carga de datos, como se observa en la figura 7 se aplica una Tarea Ejecutar SQL, indicando el SQLStatment y IsQueryStoredProcedure, para este punto se debe volver a SQL Server Management para crear un procedimiento almacenado (en la database, la carpeta Programmability y StoredProcedures), el cual se encargará de deshabilitar las restricciones de claves foráneas (útil para esta ocasión donde se desea eliminar todas las tablas para preparar el ETL y evitar errores por borrar tablas en un orden equivocado) se elimina los registros de cada tabla y por último habilita nuevamente las restricciones de claves foráneas, a través de este enlace podrá ver el código detalladamente.

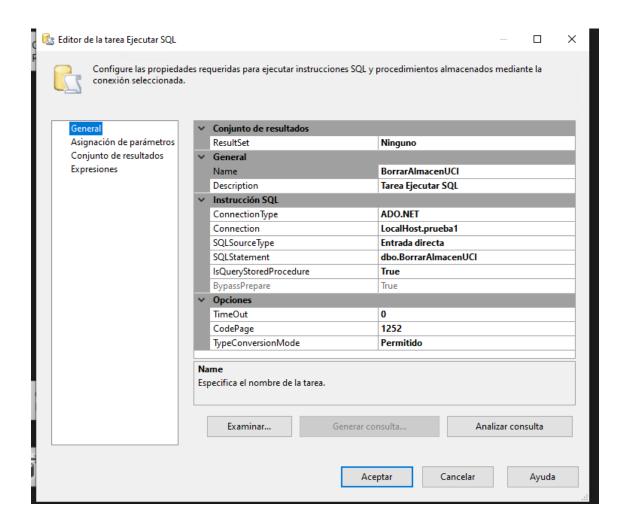


Figure 7: Ventana de información de BorrarAlmacenUCI, ya configurada

Una vez realizado el borrado de las cargas anteriores, se puede proceder con las tareas reales de carga del almacén. Es fundamental evitar la secuencialidad en el trabajo, por lo que los flujos de datos que puedan ejecutarse en paralelo deben iniciarse. Tras ejecutar el proceso *BorrarAlmacenUCI*, se inician inmediatamente los siguientes seis flujos de datos:

5.1 Carga de Región

En el caso de **Carga Region** se puede las tareas que se realizan en el flujo de datos en la figura 8, en esta misma



Figure 8: Carga de las distintas regiones para los hospitales de la base de datos elCU

5.2 Carga de Género y Etnia

Utilizamos un contenedor de secuencias. Se lleva a cabo debido a que género y etnia son jerarquías paralelas y consideramos correcto establecer un orden en sus cargas.

Para la carga de género (ver Figura 9), se utilizó como origen la base de datos [eICU Collaborative Research Database]. En lugar de emplear directamente la tabla de género, se utilizó la siguiente consulta:

SELECT DISTINCT Gender FROM Patient

El objetivo de esta consulta fue almacenar únicamente los géneros distintos, incluyendo los valores **NULL** para evitar discriminar a pacientes cuyo género no fue registrado.

Adicionalmente, se realizó una conversión de datos, ya que en el almacén de destino el campo genderString está definido como una cadena Unicode (DT_WSTR) con una longitud de 25 caracteres. Finalmente, se almacenaron los géneros distintos en el destino, y la clave genderID fue autogenerada en la nueva base de datos.



Figure 9: Carga géneros

En la carga de etnia se siguió la misma lógica utilizada para la carga de géneros. Se realizó una conversión de datos para ajustar el campo Ethnicity del origen al campo ethnicityString del destino. Finalmente, los valores procesados se almacenaron en la nueva base de datos.



Figure 10: Carga etnia

5.3 Carga Tiempo

Para la carga de la tabla tiempo 11, únicamente se trasladaron las tuplas de la tabla Paciente de la base de datos del eICU, específicamente los campos HospitalDischargeTime24 y HospitalDischargeYear. El campo TiempoID, que se encuentra en el destino, fue autogenerado automáticamente al realizar el almacenamiento de los datos.

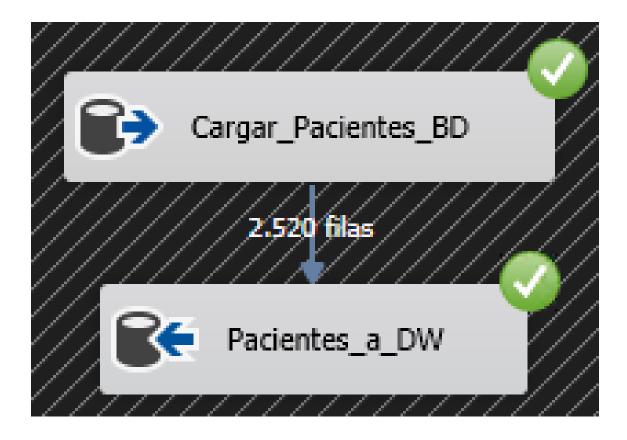


Figure 11: Carga Tiempo

5.4 Carga Priority

Para la **carga de prioridad** se siguió exactamente el mismo procedimiento utilizado para género y etnia. Se seleccionaron únicamente las distintas prioridades asociadas a los diagnósticos mediante la siguiente consulta:

SELECT DISTINCT DiagnosisPriority FROM Diagnosis

Posteriormente, los valores obtenidos se insertaron en el **Data Warehouse** (**DW**).

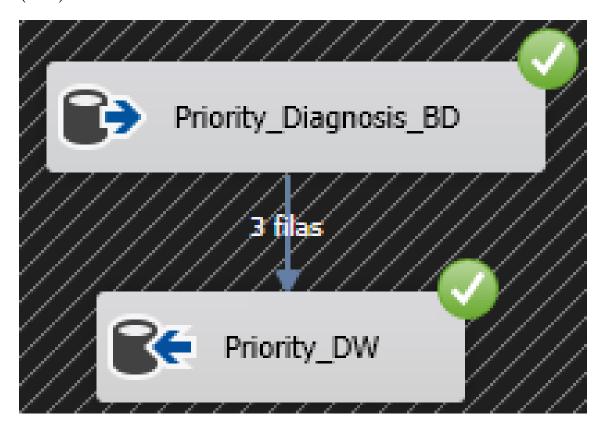


Figure 12: Carga Priority

- 5.5 Carga Tipo
- 5.6 Carga RouteAdmin

5.7 Carga Hospital

Para la carga de hospital, se utilizó como origen la tabla Hospital de la base de datos eICU. Posteriormente, se realizó una conversión del atributo Region de la tabla Hospital, transformándolo a una cadena (DT_STR) con una longitud de 64 caracteres.

Esta transformación fue necesaria para realizar un *join* mediante un elemento *lookup* de **SQL Integration Services**, cuyo objetivo fue buscar las tuplas que coincidieran en región y, a partir de ahí, obtener el correspondiente regionID 14.

Finalmente, se almacenaron los siguientes campos en el destino 15:

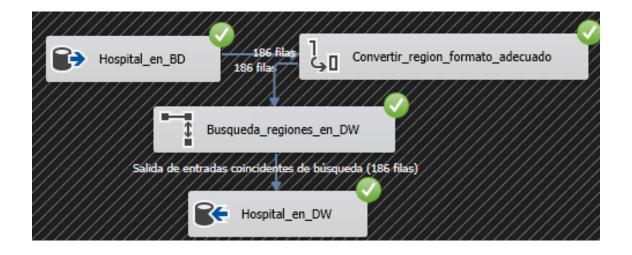


Figure 13: Carga Hospital

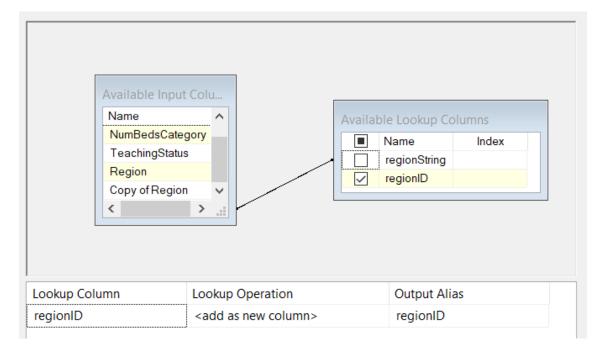


Figure 14: Busqueda_regiones_en_DW

- HospitalID del eICU, renombrado como hospitalID_og, para permitir que IngresoUCI herede la nueva clave HospitalID generada en nuestro DW.
- regionID, como clave foránea heredada de la tabla Region.

5.8 Carga Paciente

Para la carga de paciente, se utilizó como origen la tabla Patient de la base de datos eICU. En este proceso, se seleccionaron los atributos especificados en la Figura 17.

Posteriormente, se realizará un *lookup* para efectuar un *join* entre los campos Ethnicity y Gender de la base de datos eICU, y los campos ethnicityString

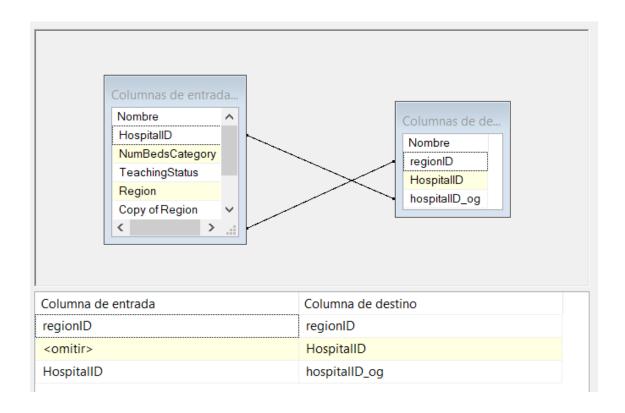


Figure 15: Hospital_en_DW



Figure 16: Carga Paciente

y genderString obtenidos a partir de la siguiente consulta sobre nuestro \mathbf{DW} (ver Figura 18):

 ${\tt SELECT * FROM Ethnicity, Gender}$

Por último, se insertarán los siguientes atributos en el destino (ver Figura 19): Además, se incluirá el atributo UniquePID, ya que es necesario para permitir que IngresoUCI herede la clave foránea (FK) de Paciente.

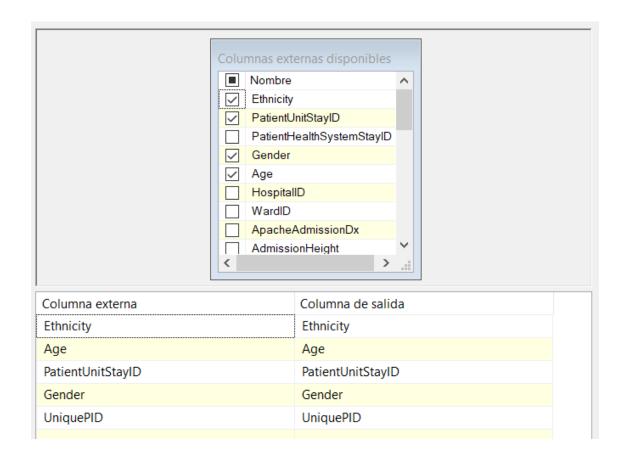


Figure 17: Origen del flujo

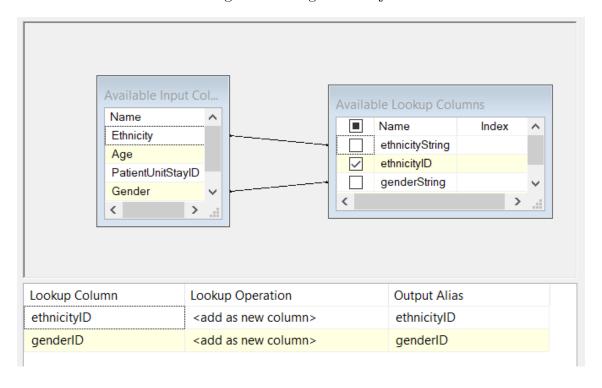


Figure 18: Busqueda_por_etnia_y_genero

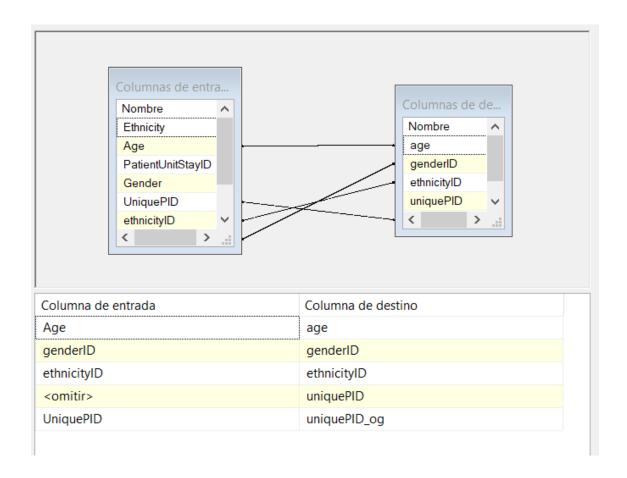


Figure 19: Pacientes_a_DW

5.9 Carga IngresoUCI

Para la carga de IngresoUCI, se utilizó como origen la siguiente consulta, mostrada en la Figura 21:

Nota: Cuando se menciona **prueba.dbo**, nos referimos a nuestra nueva base de datos/DW, ya que así la hemos denominado.

La consulta selecciona varios atributos de la base de datos eICU Collaborative Research Database y los combina con datos de nuestro Data Warehouse (DW), específicamente de las tablas Paciente, Hospital, y Tiempo, utilizando joins (uniones).

Descripción de la consulta:

• Campos seleccionados:

- TiempoID: Proviene de la tabla Tiempo, representando el identificador del tiempo del paciente.
- UniquePID: Es el identificador único del paciente, que se obtiene de la tabla Paciente.
- HospitalID: Representa el identificador del hospital, proveniente de la tabla Hospital.
- HospitalDischargeOffset: Muestra el tiempo que ha pasado desde que el paciente fue dado de alta del hospital.



Figure 20: Carga IngresoUCI

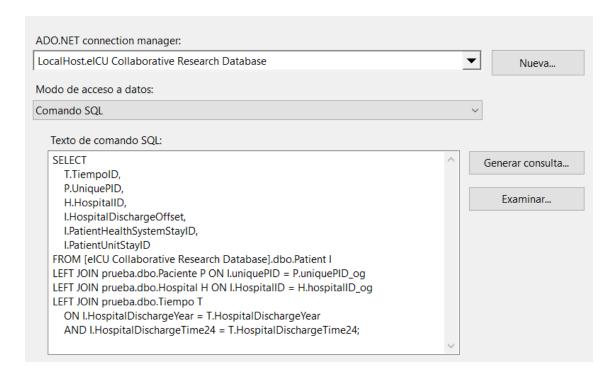


Figure 21: Paciente_en_BD

- PatientHealthSystemStayID: Identificador de la estancia del paciente en el sistema de salud.

- PatientUnitStayID: Identificador de la unidad en la que el paciente estuvo durante su estancia.
- Proceso de unión (joins): La consulta usa LEFT JOIN para combinar las tablas, lo que significa que se toman todos los registros de la tabla de la izquierda (de la base de datos eICU) y los registros coincidentes de las tablas de la derecha (de nuestro DW). Si no hay coincidencia, los valores de las tablas del DW serán NULL.
 - Primer JOIN: Se une la tabla Patient de eICU (aliased como I) con la tabla Paciente de nuestro DW (aliased como P), usando el campo uniquePID de ambas tablas. Aquí, se mapea el uniquePID de eICU al campo uniquePID_og de Paciente en el DW.
 - Segundo JOIN: Se une la tabla Patient de eICU con la tabla Hospital en nuestro DW (aliased como H), usando el campo HospitalID. Se compara HospitalID de eICU con hospitalID_og en Hospital en el DW.
 - Tercer JOIN: Se une la tabla Patient de eICU con la tabla Tiempo en el DW (aliased como T), utilizando los campos HospitalDischargeYear y HospitalDischargeTime24 de eICU y comparándolos con los mismos campos en la tabla Tiempo de nuestro DW.
- Resultado final: La consulta extrae los datos de eICU y los enlaza con la información relevante de nuestro DW, lo que permite que los registros en la tabla IngresoUCI contengan las claves correctas de las tablas de nuestro DW (como Paciente, Hospital, y Tiempo).

Por último, se insertaron los datos en IngresoUCI de nuestro DW:

5.10 Carga Diagnosis

Para la carga de Diagnosis, se tomó como origen la tabla Diagnosis del eICU. Posteriormente, se realizó una conversión del atributo DiagnosisPriority a tipo cadena [DT_STR] con longitud 10.

A continuación, se realizará un *join* entre Copy of DiagnosisPriority y priorityString de la tabla Priority de nuestra base de datos/DW, y se seleccionará el priorityID para que pueda ser heredado por Diagnosis en nuestro **DW** (ver Figura 24).

Estos serán los atributos de Diagnosis en nuestro DW:

6 Dificultades encontradas

Una de las principales dificultades fue la complejidad de la base de datos eICU, que incluye una gran cantidad de tablas y atributos. Esto exigió un análisis detallado para identificar las tablas y campos clave en un modelo centrado en pacientes con enfermedades respiratorias. Además, enfrentamos problemas de permisos al intentar visualizar el modelo relacional en SQL Server, lo que requirió modificar las autorizaciones del propietario de la base de datos para acceder a los diagramas de relación.

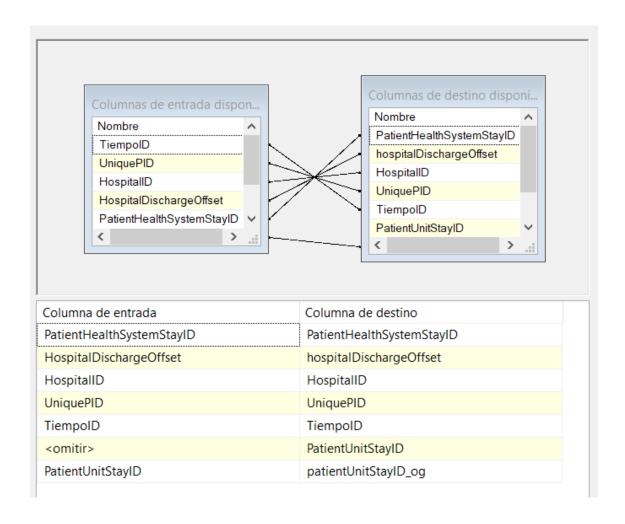


Figure 22: Ingreso_UCI_DW

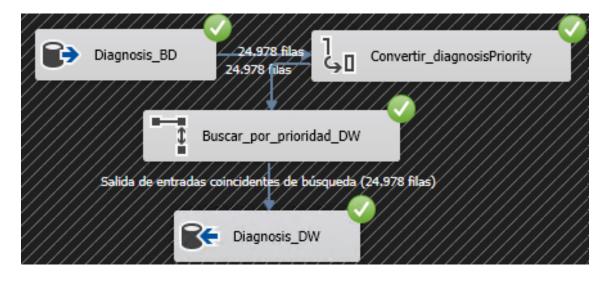


Figure 23: Carga Diagnosis

Además el comienzo del trabajo podría ser lo más angustioso, al tener tanta información y opciones llega a ser un poco abrumador, desde la selección de una población concreta y modelar un almacén para dicha población termina dejando

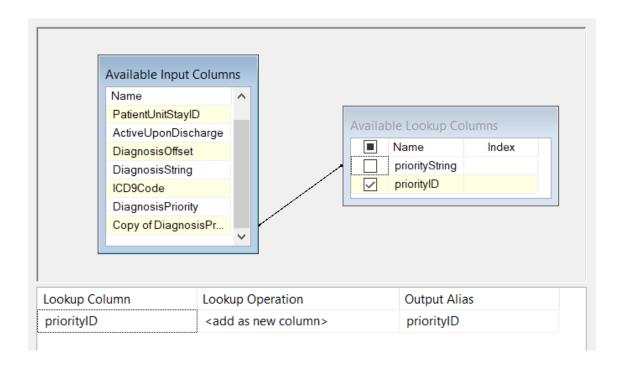


Figure 24: Buscar_por_prioridad_DW

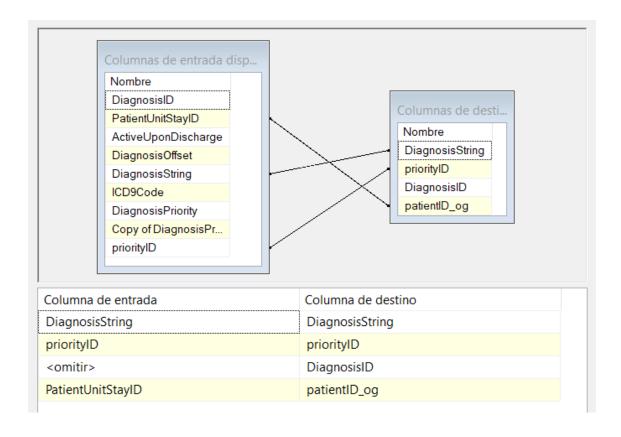


Figure 25: Diagnosis_DW

muchas dudas sobre cuantas tablas es esperable eliminar, si se esta simplificando de más o se esta tomando una decisión que afectará los siguientes apartados.

7 Conclusiones

8 Github y conjunto de instrucciones para su correcto despliegue en SQL Server.

Todo el proyecto está accesible en github [2] donde se detalla más específicamente como desplegar en SQL.

References

- [1] eICU Collaborative Research Database. eICU Collaborative Research Database. https://eicu-crd.mit.edu/about/eicu/. Accessed: 2024-11-14. 2024. URL: https://eicu-crd.mit.edu/about/eicu/.
- [2] Diegodepab. Almacén UCI Sanitaria. https://github.com/Diegodepab/almacen_UCI_Sanitaria. Accessed: 2024-11-14. 2024. URL: https://github.com/Diegodepab/almacen_UCI_Sanitaria.



E.T.S de Ingeniería Informática Bulevar Louis Pasteur, 35 Campus de Teatinos 29071 Málaga